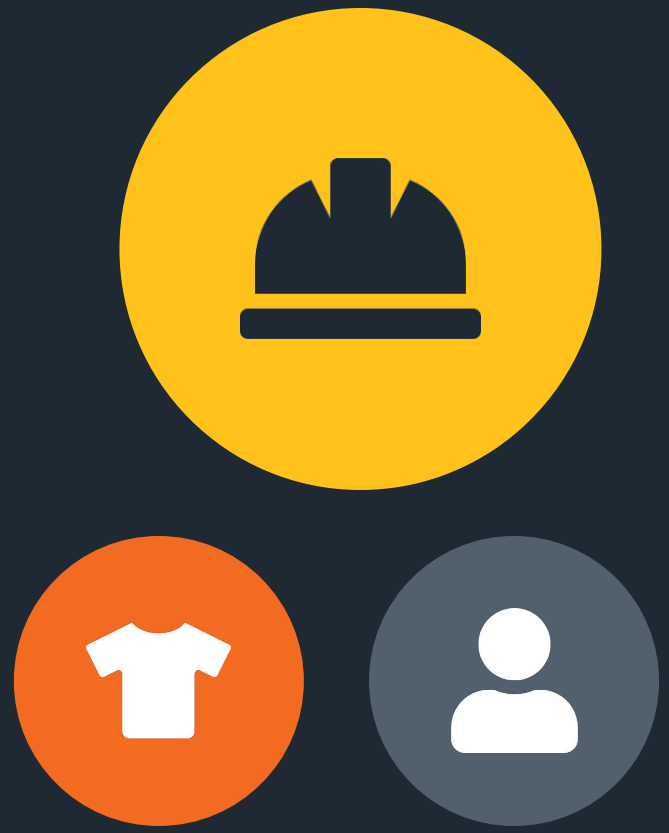
Detección de EPP con Visión Computacional

Identificación automática de casco y chaleco en áreas operativas

Prueba técnica · Científico de Datos en Visión Artificial · Octubre 2026



Edison David Serrano Cárdenas

Magíster en Ciencias con Orientación en Matemáticas Aplicadas - CIMAT

Del píxel al evento accionable

- Detectar personas sin casco o sin chaleco dentro de zonas operativas.
- Convertir las detecciones en eventos con severidad.
- Medir desempeño: el modelo, la solución completa y su operación posterior al despliegue.

Repositorio reproducible: configuración separada del código, semillas fijas, notebooks, requirements, python scripts.
https://github.com/edserranoc/PPE-detection-using-computer-vision/tree/main

Imágenes
con polígonos de zona de interés (ROI)

Detector YOLOv8n
persona, casco, chaleco y sus ausencias

Reglas de negocio
ROI, persistencia, duplicados

Evento con severidad
media · alta · crítica

Evaluación y monitoreo
métricas, trazabilidad y nuevo ciclo

Un dataset limpio y casi balanceado

kaggle

4 060

imágenes: 3 248 train · 406 val · 406 test

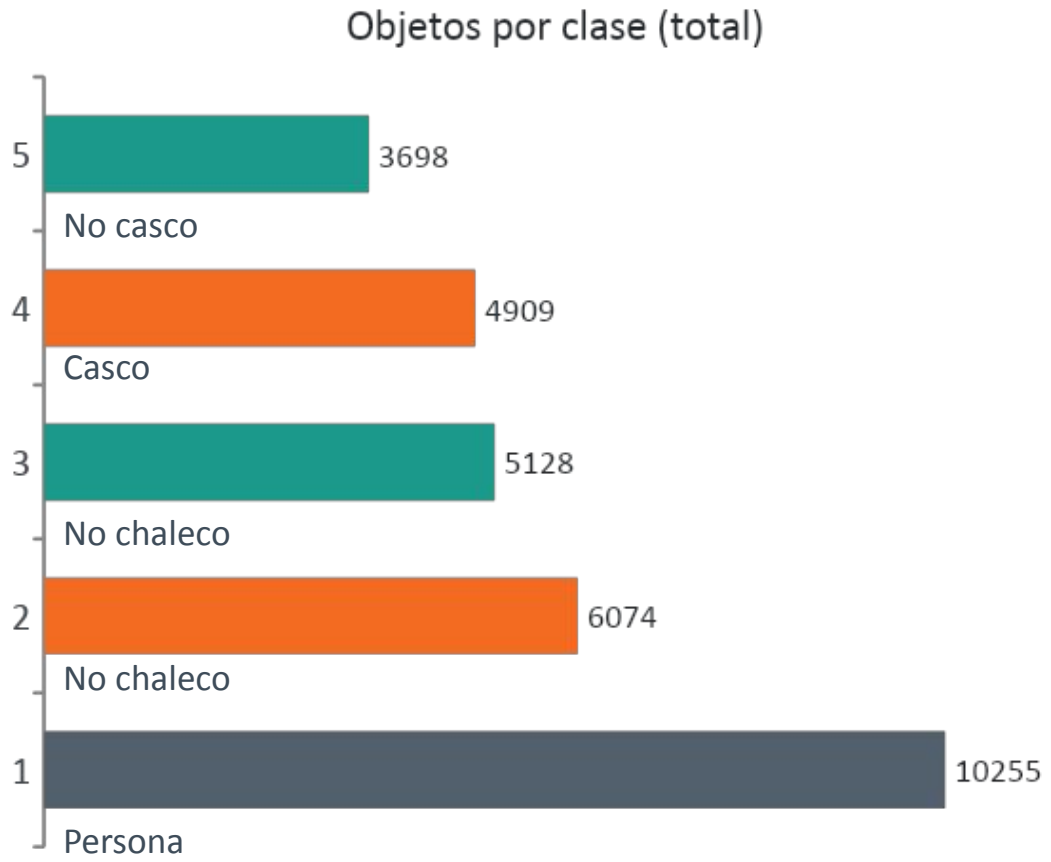
30 064

objetos anotados, 7.4 por imagen

5

clases: persona, casco, chaleco y sus ausencias





Nota: todas las imágenes son de 640×640. El dataset es de libre acceso. Sin imágenes corruptas, etiquetas faltantes o cajas inválidas

Aumentos pensados para la escena

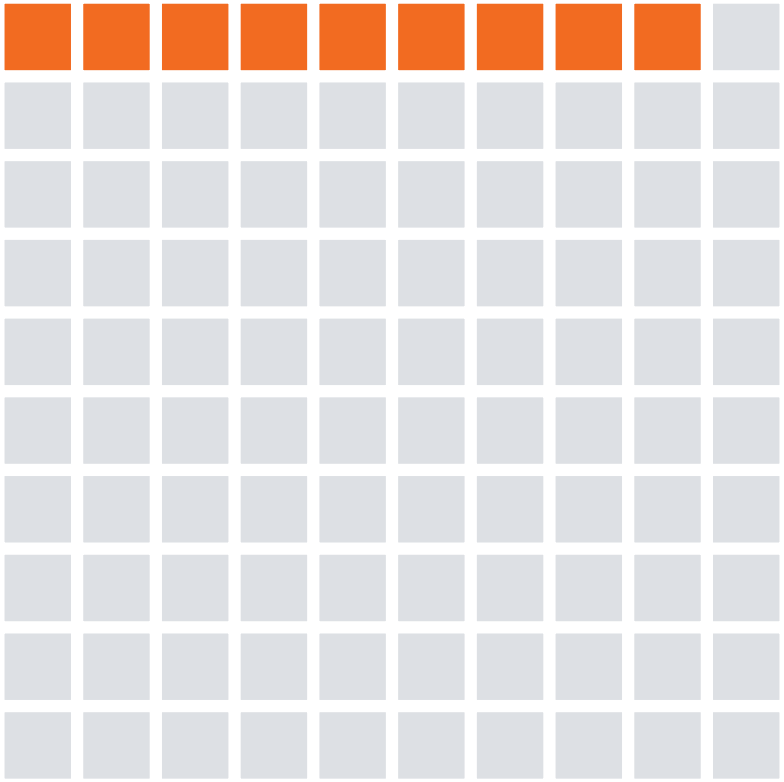
Aumento	Por qué
Color HSV (0.015 · 0.7 · 0.4)	Cambios de iluminación y de cámara
Volteo horizontal (0.5)	Las escenas son simétricas
Sin volteo vertical ni rotación	Personas de pie y cámaras fijas; mantiene cabeza arriba y torso abajo
Traslación 0.1 · escala 0.5	Variación de posición y de distancia a la cámara
Mosaic (se apaga en las últimas 10 épocas)	Más contexto y más objetos pequeños por imagen
Sin MixUp	Mezclar imágenes confunde casco con no casco



Aumentar lo que cambia en producción

Luz, distancia y cámara sí. Volteo vertical y rotación no: rompen la geometría que usa la asociación persona–EPP.

Fuga entre particiones: 8.9 % de val/test



Cada cuadro es el 1 % de las imágenes de val y test; en naranja, las que tienen un gemelo en train.

8.9 %

de las imágenes de val y test (72 de 812) tienen un gemelo casi idéntico en train

Causa: fotogramas de los mismos videos repartidos entre particiones (p. ej. IMG_3103_mp4-17).

Efecto: las métricas de val y test pueden ser optimistas.

Decisión: conservar la partición y reportar las métricas con y sin las imágenes gemelas.

Entrenamiento: buen camino, sin converger

Modelo
YOLOv8n con pesos COCO

Entrada y lote
640 px · batch 8

Entrenamiento
20 épocas · AdamW · lr0 0.001

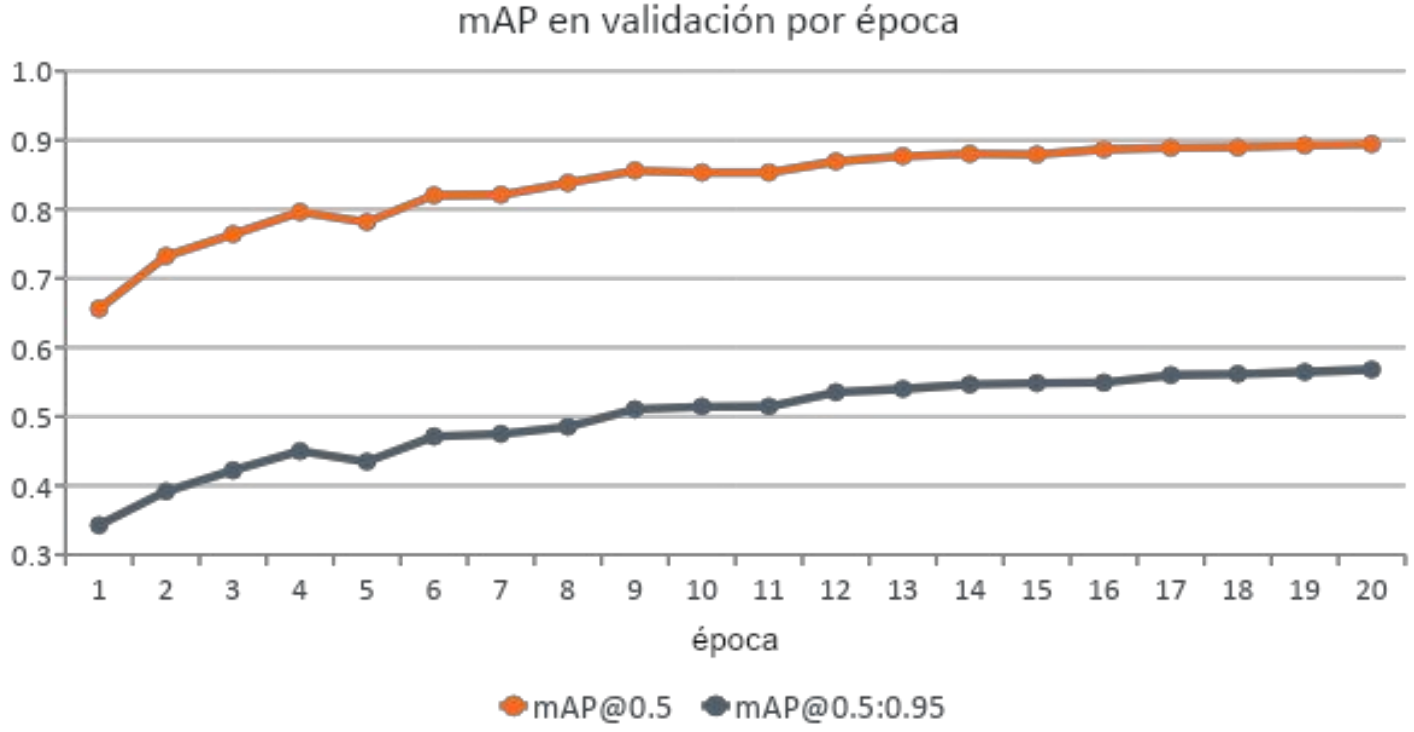
Reproducibilidad
semilla 42 · determinista

Tiempo
58 min (174 s por época)

Mejor checkpoint
época 20, por fitness 0.1·mAP50 + 0.9 ·mAP50-95

GPU - RAM

NVIDIA GeForce GTX 1050 Mobile - RAM 12gb



+0.008 de mAP@0.5:0.95 en las últimas 3 épocas: aún mejora

Pérdida de caja 1.14 (train) vs 1.18 (val): sin sobreajuste

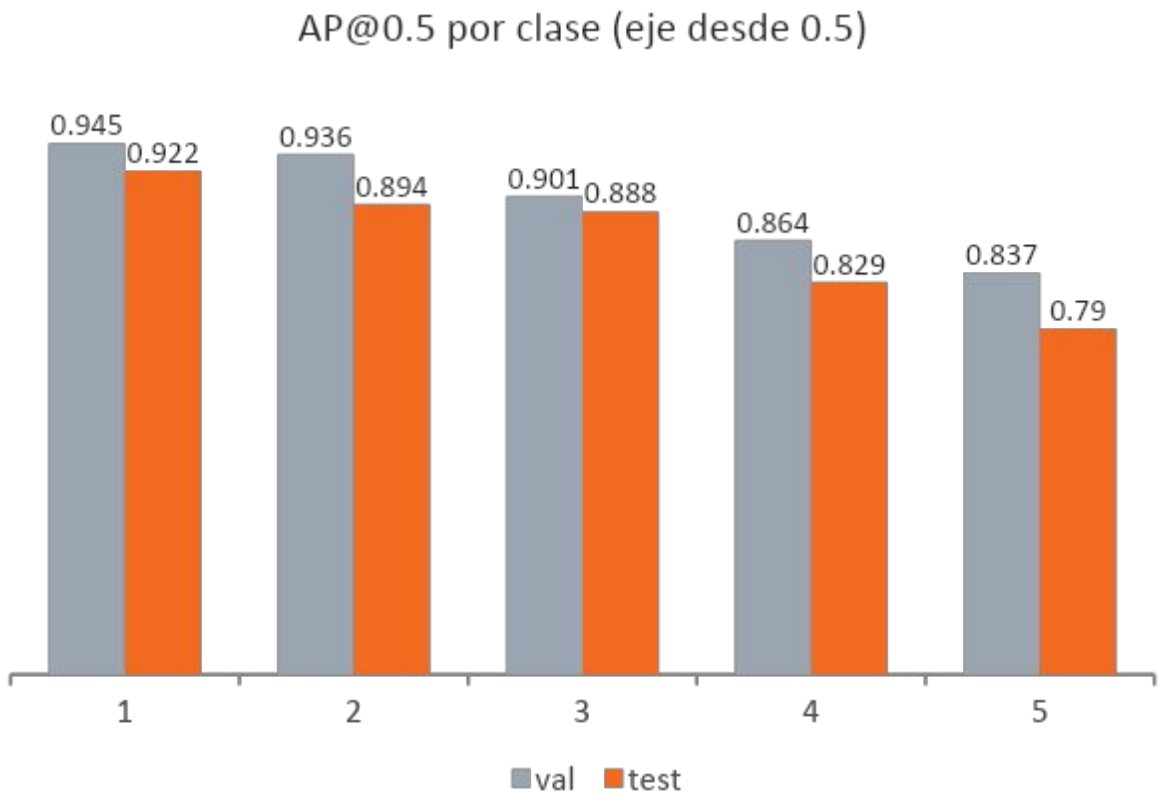
Las clases de ausencia son el punto débil

0.865

mAP@0.5 (test)

0.558

mAP@0.5:0.95 (test)



Test queda 3 puntos por debajo de val (mAP@0.5: 0.865 frente a 0.897). Las cifras son las de Ultralytics: P/R/F1 en el umbral que maximiza F1; las del pipeline se miden en la evaluación de predicciones.

no_helmet: AP@0.5 de 0.79 y recall de 0.72, la clase que alimenta los eventos de severidad alta

Pipeline robusto ante cualquier resolución

Leer y validar → **Letterbox a 640×640** → **Detectar** → **A coordenadas originales** → **Umbrales y NMS** → **Reglas y JSONL**

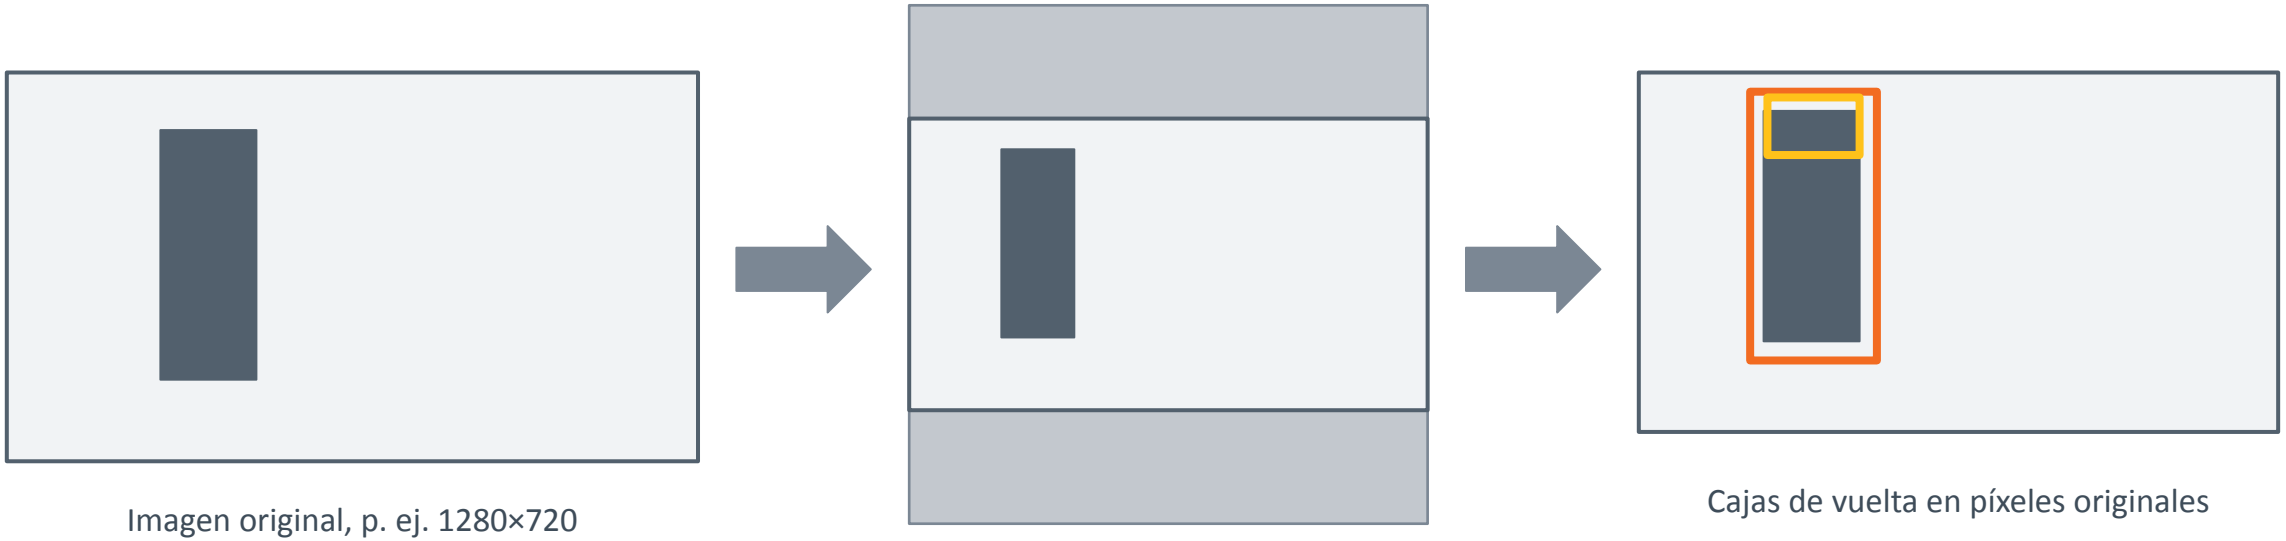


Imagen original, p. ej. 1280×720

640×640 con bordes grises (letterbox)

Cajas de vuelta en píxeles originales

letterbox conserva la proporción (por defecto) · **resize** estira y deforma · **none** deja el ajuste a Ultralytics. Un archivo corrupto no detiene el lote.

Reglas de negocio configurables

Condición	Evento	Severidad
Persona fuera del ROI	no genera evento	—
Persona sin chaleco	persona_sin_chaleco	media
Persona sin casco	persona_sin_casco	alta
Sin casco y sin chaleco	persona_sin_casco_y_chaleco	crítica

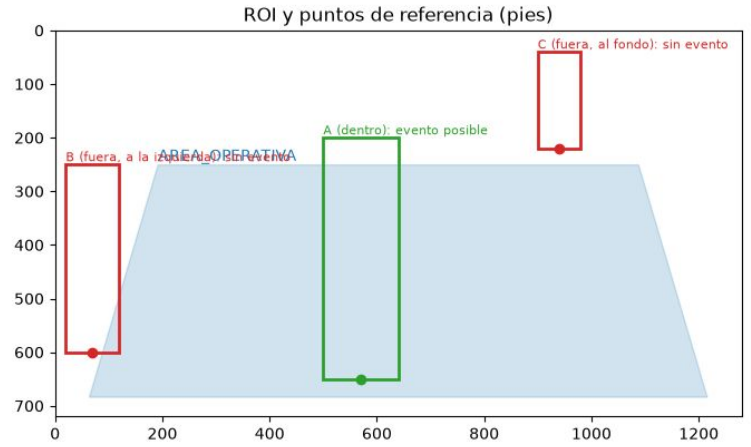
Severidades y tipos de evento se cambian en configs/rules.yaml, sin tocar el código.

Nota: No se evaluaron ejemplos visuales para ver el desempeño de las reglas de negocio.

Asociación: el EPP está dentro de la persona (≥ 50 % de su área) y en la franja cabeza o torso.

ROI: polígonos por cámara; cuenta la posición de los pies.

Persistencia: 1 frame en imágenes sueltas (≥ 5 frames en vídeo)



Tres formas de decidir que falta un EPP

association

Falta el EPP si no hay uno positivo asociado a la persona.

Riesgo: Falsas alarmas si el detector omite un casco visible.

explicit

Falta sólo si el modelo detecta no_helmet o no_vest asociado, con más confianza que el positivo.

Riesgo: Se pierden incumplimientos que el modelo no «ve».

hybrid

Falta salvo que haya un positivo asociado con confianza igual o mayor que la del negativo.

Riesgo: Intermedio: depende de los umbrales y de la asociación.

por defecto

Todo queda registrado y es trazable

```
{"prediction_id": "uuid",
 "source_id": "video_001", "camera_id": "CAM_01",
 "frame_id": 128, "timestamp_seconds": 4.27,
 "model_version": "1.0.0", "class_name": "persona",
 "confidence": 0.93,
 "bbox": {"x1":120,"y1":100,"x2":420,"y2":690},
 "track_id": 15, "inside_roi": true,
 "event_generated": true,
 "event_type": "persona_sin_casco",
 "severity": "alta"}
```

predictions.jsonl

una línea por detección, con ROI, track y evento

events.jsonl

eventos consolidados, con latencia y enlace a la predicción

Trazabilidad

schema_version, run_id, model_version, hash de configuración y semilla

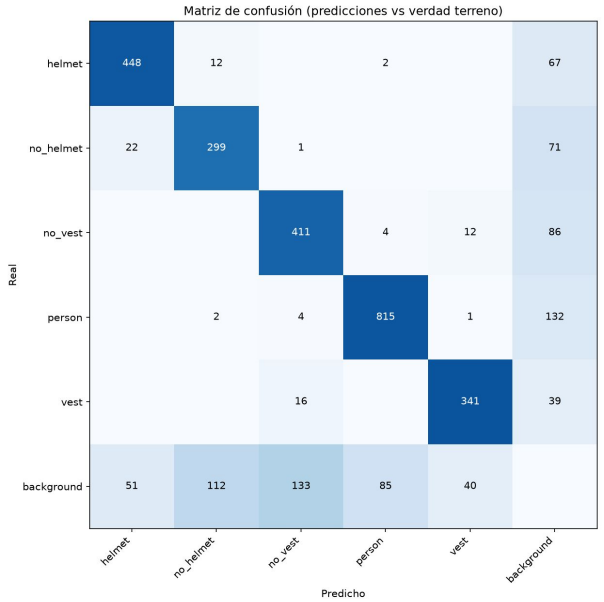
metrics.json

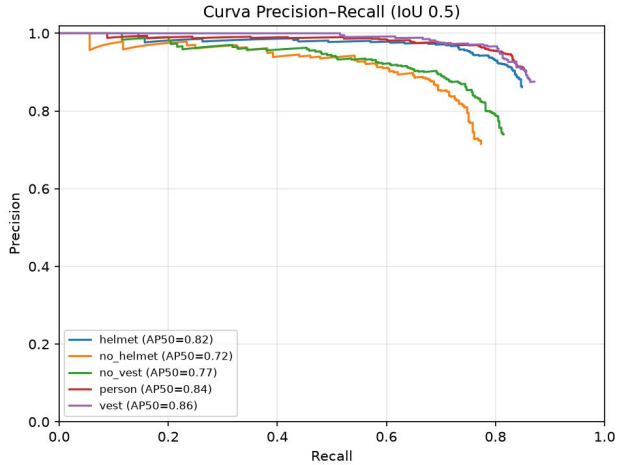
volumen, rendimiento, calidad y segmentación de la corrida

Desempeño de las predicciones

POR COMPLETAR

Clase	TP	FP	FN	P	R	F1
person	817	89	137	0.9018	0.8564	0.8785
helmet	449	72	80	0.8618	0.8488	0.8552
no_helmet	304	121	89	0.7153	0.7735	0.7433
vest	345	49	51	0.8734	0.8712	0.8734
no_vest	418	147	95	0.7398	0.8148	0.7755





Contra ground_truth.jsonl (imágenes revisadas) · IoU 0.5 · mAP@0.5 y @0.5:0.95 · se explican las imágenes sin detecciones y las anotaciones sin predicción.

Desempeño de la lógica de eventos

POR COMPLETAR

—

F1 de eventos

precision y recall en el detalle

—

Eventos omitidos

con su causa probable

—

Latencia

condición → evento (s)

Estrategia	Precision	Recall	F1	Omitidos	Latencia/ ms
association	0.6944	0.7438	0.7183	155	26.55
explicit	0.7560	0.7322	0.7439	162	21.15
hybrid (por defecto)	0.6947	0.7521	0.7222	150	20.01



Los eventos esperados se derivan de las anotaciones: revisarlos a mano antes de llamarlos verdad terreno.

Desglose por tipo de evento, cámara y fuente en event_metrics.json

Monitoreo operacional

Volumen

archivos, frames, detecciones y eventos

Rendimiento

tiempo total, ms por frame, FPS y archivos fallidos

Calidad

confianza por clase, descartes y distribución de clases

Segmentación

resultados por clase, cámara, fuente y periodo

Trazabilidad

modelo, hash de configuración, fecha y semilla

FPS del pipeline completo y calidad de la corrida: pendiente de ejecutar la inferencia sobre test/images

Limitaciones y siguientes pasos

Limitaciones

- Fuga entre particiones: 8.9 % de val/test
- Solo 20 épocas: el modelo no ha convergido
- El dataset tiene una única resolución (640×640)
- Eventos esperados derivados de las anotaciones
- Hardware limitad.

Siguientes pasos

- Entrenar 50–100 épocas
- imgsz mayor o YOLOv8s para objetos pequeños
-
- ByteTrack para video real

Conclusiones

1

Un pipeline completo y reproducible
datos validados, modelo, reglas, JSONL, evaluación y monitoreo.

2

El detector rinde bien, pero la ausencia de EPP necesita más entrenamiento
mAP@0.5 de 0.865 en test; no_helmet y no_vest son las clases débiles.

3

Falta cerrar el ciclo con datos reales
medir predicciones y eventos de punta a punta, y cuantificar el efecto de la fuga.

Gracias · ¿preguntas?